1. Define qué es Big Data y menciona al menos tres características clave.

Big Data es un conjunto de datos de gran volumen que son difíciles de gestionar, procesar y analizar por su volumen y complejidad.

Caracteristicas

1. Cantidades altas de datos que se generan, procesan y almacenan. (volumen)
2. Variedad es otra caracteristica ya que los datos pueden venir de distintas formas (estructurado y no estructurados)
3. Velocidad de formacion de estos datos, asi como se generan tambien se busca procesarlos y analizarlos.

2. ¿Cuáles son las tres "V" originales de Big Data? Explícalas brevemente.

1. Volumen - Masividad de los datos generados
2. Velocidad – Asociado con el tiempo de procesamiento
3. Variedad – Diversidad en las estreucturas de los datos

3. Enumera al menos cinco fuentes de datos que puedan contribuir al volumen de datos en un entorno de Big Data.

Empresas mediante sistemas de gestion interna. Ya sea de manera financiera, recursos humanos o produccion.

Las redes sociales tambien contribuyen al volumen de datos en un entorno de Big Data al generar publicaciones (textos, videos y fotos), reacciones y comentarios.

Los hospitales generan gran cantidad de datos que se pueden hacer anonimos para fines de investigacion sin violar la privacidad de los pacientes.

Los bancos contribuyen al volumen de datos que se generan ya que todos los pagos se registran y son masivos.

Los datos meteorologicos o ambientales tambien contribuyen al al volumen de datos en un entorno de Big Data.

4. Explica la diferencia entre datos estructurados, no estructurados y semi-estructurados en el contexto de Big Data.

Datos Estructurados - tienen un formato bien definido (filas y columnas) y son fáciles de buscar y analizar mediante algoritmos tradicionales.

Datos No Estructurados - no tienen una organización predefinida, no se pueden almacenar fácilmente en bases de datos tradicionales ya que no es facil de reconocer un formato.

Datos Semi Estructurados - son la combinacion de los dos tipos de datos, es decir si tienen una estructura que organiza a los datos pero no siguen un formato fijo. Lo que los organiza son etiquetas o algun tipo de marcador.

5. ¿Por qué el procesamiento en tiempo real es un desafío importante en Big Data? Proporciona un ejemplo.

El procesamiento en tiempo real es un desafio dado a que se genera un gran volumen de datos cada segundo, para almacenarlos y procesarlos se requiere una infraestructura con gran capacidad sin delays. Por ejemplo es fundamental lograr procesar los datos en tiempo real para posicionarse y generar mas ventas en linea. Las recomendaciones personalizadas requieren procesamiento en tiempo real para que el cliente descubra productos relevantes según sus intereses y, finalmente, los consuma.

6. ¿Qué son los modelos sintéticos en Big Data y para qué se utilizan?
Son réplicas de datos reales que se generan para imitar las propiedades y patrones de un conjunto de datos real sin revelar la información sensible o confidencial de los datos originales. Se utilizan para mantener privacidad de los datos reales, probar algoritmos y modelos de análisis en datos sintéticos antes de implementarlos en datos reales y tambien para ampliar el tamaño del conjunto de datos y mejorar la precisión de los modelos predictivos.

7. Describe brevemente la importancia de la variedad de datos en Big Data y cómo puede afectar el análisis de datos.
Es importante la variedad de los datos ya que enriquece el análisis al integrar diferentes tipos, como texto, audio, video, y datos numéricos, logrando asi obtener una visión más completa y detallada de lo que esta pasando.

8. ¿Cuál es el papel de Hadoop en el procesamiento y almacenamiento de Big Data? Menciona al menos dos de sus componentes principales.
El papel de hadoop en el procesamiento y almacenamiento de Big Data es distribuir cantidades grandes de datos a través de clusters de servidores y procesarlos en paralelo buscando asi mejorar el rendimiento y reducir los tiempos de procesamiento.
Componentes principales: MapReduce, Hadoop Distributed File System, Hive y Oozie

9. ¿Qué significa el término "veracidad" en el contexto de Big Data y por qué es importante?
La veracidad significa la calidad y confiabilidad de los datos donde se busca tener precisión, consistencia y exactitud de los datos. Es importante ya que ayuda a tomar decisiones basadas en datos confiables y reducir errores por sesgos. Además aumenta la confianza en los análisis.

10. ¿Cuáles son algunos de los desafíos de seguridad y privacidad que se enfrentan en el manejo de Big Data? Proporciona ejemplos.
El manejo de Big Data presenta grandes desafíos en seguridad y privacidad debido a la cantidad de datos sensibles involucrados. Las regulaciones/leyes como el RGPD y la HIPAA imponen estrictas reglas que, de no cumplirse, pueden resultar en fuertes sanciones y dañar la reputación de las empresas. Los datos médicos y financieros son especialmente vulnerables; por ejemplo, la información de hospitales y bancos debe protegerse para evitar consecuencias graves como el robo de identidad o fraudes financieros.

11. Explica cómo se pueden utilizar las redes sociales en el análisis de Big Data y menciona al menos dos tipos de análisis que se pueden realizar.
Las redes sociales proporcionan una visión profunda sobre las interacciones y opiniones de los usuarios. Los datos pueden utilizarse para realizar análisis de sentimiento para evaluar la percepción pública sobre un producto, servicio o tema específico. Tambien pueden permitir identificar tendencias nuevas y patrones en el comportamiento, como preferencias, hábitos de consumo y niveles de engagement. Por su naturaleza masiva y en tiempo real de los datos, se pueden detectar cambios en la opinión pública rapido y funciona para ajustar estrategias de marketing, tomar decisiones informadas y desarrollar mejores productos que se adapten a las necesidades.

12. ¿Qué es el aprendizaje automático (machine learning) y cómo se aplica en el análisis de Big Data?
El machine learning se enfoca en crear algoritmos que permiten a las máquinas aprender a partir de los datos sin requerir una programación para cada tarea específica. En Big Data el machine learning se aplica a grandes rasgos para automatizar procesos, encontrar patrones ocultos, clasificar los datos en grandes volumenes y realizar predicciones precisas. Esto es muy importante cuando la cantidad de datos es demasiado grande o compleja para ser procesada manualmente permitiendo la segmentación de clientes y el análisis predictivo de tendencias entre muchsas otras cosas mas. Además las maquinas van aprendiendo y asi mejorando medida que reciben más información.

13. ¿Cuáles son las ventajas y desventajas del almacenamiento distribuido en Big Data?
Desventajas - Es mas costoso ya que se necesita mas capacidad de procesamiento por lo que solo se debe de usar cuando se tiene un gran volumen de datos. Necesita mas mantenimiento.
Ventajas- Es tolerante a fallos, es escalable y el procesamiento puede ser en paralelo, tiene mayor capacidad de almacenamiento y brinda mayor confiabilidad y disponibilidad de datos.

14. ¿Por qué la escalabilidad es un aspecto crucial en los sistemas de Big Data?
La escalabilidad es esencial porque permite manejar el creciente volumen de datos sin comprometer el rendimiento. Asi asegura flexibilidad y eficiencia en costos. De esta manera su rendimiento no disminuye y sigue optiomo aun que el volumen de los datos crezca.

15. Explica la importancia de la visualización de datos en el análisis de Big Data. Menciona al menos dos tipos de visualización.
La visualizacion de los datos facilita la forma en que se explica la informacion. Ayuda a representar de forma grafica lo que se encontro en el analisis haciendo asi facil ver las tendencias o patrones encontradas. Los tipos mas comunes para visualizar la informacion son lasgraficas de barras, graficas de lineas, diagramas de dispersion e histogramas.

16. ¿Qué es la variabilidad en Big Data y cómo puede afectar el análisis de datos?
La variabilidad se refiere a la inconsistencia en los datos, tanto en su formato como en su contenido, surge de la manera en que se generan, recopilan y almacenan los datos. En el análisis de datos dificulta su combinación en conjuntos coherentes, puede introducir errores e inconsistencias durante el procesamiento, afectando la precisión de los resultados. Además, puede incrementar la complejidad del análisis y de la visualización, provocando que los resultados sean menos claros.

17. Describe dos aplicaciones prácticas de Big Data en la industria o la investigación.
Una aplicación práctica de Big Data es el análisis de una industria manufacturera para buscar la optimización de la producción y/o la cadena de suministro. Otra aplicación práctica de Big Data es en el sector de la salud, donde se pueden analizar datos para identificar patrones que prevengan enfermedades. Además, se pueden analizar grandes volúmenes de datos médicos para mejorar la atención a los pacientes y optimizar los recursos.

18. ¿Qué significa el término "valor" en el contexto de Big Data y cómo se puede obtener valor a partir de los datos?
El valor radica en transformar los datos en información y conocimientos significativos y útiles que guíen acciones y decisiones estratégicas. Para lograrlo, es necesario realizar análisis y aplicar técnicas de procesamiento y minería de datos que permitan extraer conocimientos y patrones valiosos.

19. ¿Cuál es el papel de Spark en el procesamiento de Big Data y qué ventajas ofrece en comparación con otras tecnologías?

Spark es un frameworks para el procesamiento de datos en tiempo real y el análisis de Big Data. Sirve para facilitar el procesamiento paralelo y distribuido de grandes volúmenes de datos de forma eficiente y rápida. Ventajas: alta velocidad de procesamiento, soporte para diversas fuentes de datos, una API intuitiva, escalabilidad y facilidad de uso.

20. Enumera tres desafíos éticos y legales relacionados con el uso de Big Data en la toma de decisiones.

Un desafio es el sesgo que puede generarse en los algoritmos, lo que puede llevar a decisiones discriminatorias. Los algoritmos pueden reforzar sesgos preexistentes y asi llevar a que se tomen decisiones basadas en datos que no son justos. Además, existe el reto relacionado con la privacidad de los datos, ya que la recolección de información genera preocupaciones sobre el consentimiento de los individuos. Recopilar y analizar grandes volúmenes de datos personales también puede infringir leyes si la recolección no se realizó de manera legal. Otro desafío importante es la desinformación y la manipulación de la opinión pública que se puede lograr generar. Se puede dirigir información específica a grupos particulares de personas, lo que puede influir en sus percepciones y decisiones. Esto puede amplificar narrativas incorrectas, creando burbujas informativas donde las personas solo reciben información que refuerza sus creencias preexistentes.